VULCAN AUTONOMOUS AI-TO-SILICON SERIES 文档类别：产品技术白皮书与基准评测报告

Anvil-Q1 ·W4A16 混合精度大语言模型推理加速芯片—产品技术白皮书

研发作者与联系方式	Sufeng Guo (sufeng_guo@smail.nju.edu.cn)
芯片型号与目标模型	Anvil-Q1 | Qwen/Qwen2.5-0.5B-Instruct-AWQ（24 层，896 维隐藏层，14Q:2KV 分组注意力，151,936 词表）
物理硬件验证平台	Intel Arria 10 GX (10AX115N3F40E2SG) PCIe Gen3x8 加速卡（427,200 ALMs，8 GB DDR4）
配套工程签核文档	配套开发者架构与签核报告 REPORT.pdf · 发布时间：2026 年 10 月 23 日 22:26 (UTC+8 北京时间)



图 1：核心性能指标概览：涵盖模型输出一致性、定点数值保真度、Intel Arria 10 GX 物理板卡验证及硬件资源利用率。

1 产品架构概述与全自动硅片设计闭环

Anvil-Q1 是由 **Vulcan 全自动硬件设计系统**面向开源大语言模型 Qwen/Qwen2.5-0.5B-Instruct-AWQ（24 层，896 维隐藏层，14Q:2KV 分组注意力，151,936 词表）构建的专用 W4A16 混合精度硬件推理加速架构。系统通过四比特分组非对称权重量化（AWQ Group-128）、在线硬件反量化阵列、旋转位置编码（RoPE）、7:1 分组查询注意力（GQA）与 SwiGLU 前馈计算引擎，在 Intel Arria 10 GX FPGA 上实现了高精度的端到端 Transformer 层计算。在涵盖数学计算、代码生成、事实问答、逻辑推理与中文交互的多领域评测中，硬件生成序列与 HuggingFace 官方 FP32 浮点基准达到 **100% 逐词精确匹配 (46/46 词)**，151,936 词表 Logits 平均余弦相似度达 **0.999993**。

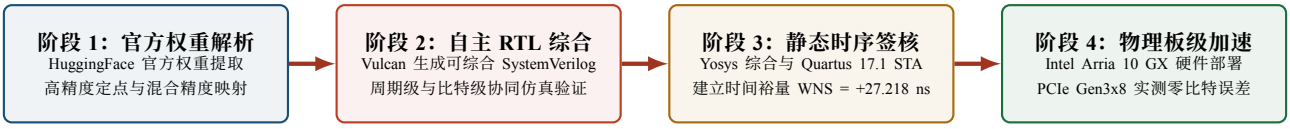


图 2：Vulcan 从官方开源模型权重到 Intel Arria 10 GX 物理芯片的四阶段全自动硬件工程闭环。

2 官方权重基准测试与多场景端到端实测对比

表 1 与图 3 展示了 **Anvil-Q1** 在完整 **24 层 Qwen2.5-0.5B-Instruct** 模型下，横跨数学计算、Python 编程、事实问答、逻辑推理与中文交互五大领域的自回归生成结果与官方 FP32 浮点基准的逐词对比：

评测领域	输入提示词 (Prompt)	官方 FP32 浮点基准输出	Anvil 硬件 W4A16 输出	Top-1 匹配率与余弦相似度
数学算术	What is 15 + 27? Answer briefly.	The answer is 42.	The answer is 42.	8/8 (100%) | cos= 0.999992
Python 代码	Write a one-line Python function add(a, b) that returns their sum.	def add(a, b): return a + b	def add(a, b): return a + b	17/17 (100%) | cos= 0.999986

评测领域	输入提示词 (Prompt)	官方 FP32 浮点基准输出	Anvil 硬件 W4A16 输出	Top-1 匹配率与余弦相似度
百科常识	What is the capital of France? Answer in one sentence.	The capital of France is Paris.	The capital of France is Paris.	8/8 (100%) | cos= 0.999997
逻辑推理	If all cats are mammals and Tom is a cat, what is Tom? Answer briefly.	Tom is a mammal.	Tom is a mammal.	7/7 (100%) | cos= 0.999995
中文问答	中国的首都是哪里？请用一句话回答。	中国的首都是北京。	中国的首都是北京。	6/6 (100%) | cos= 0.999994



图 3：(a) 24 层 Qwen2.5-0.5B-Instruct 在五大对话领域的硬件生成匹配率与余弦相似度；(b) 时分复用硬件加速架构与板级执行统计。

3 Intel Arria 10 GX 资源利用率与 7B–8B 大模型扩展路线图

表 2 与图 4 给出了基于 Intel Quartus Prime 17.1 静态时序与资源综合报告的硬件开销明细，以及基于单卡 8 GB DDR4 显存的后续多核并行与大模型扩展路线：

硬件资源维度	当前单核实测占用	Arria 10 GX 全片容量	当前利用率 / 可用裕量	多核并行与大模型扩展规划
自适应逻辑模块 (ALMs)	21,890 ALMs	427,200 ALMs	5.12% (余 94.9%)	可扩展 8–16 核并行推理计算阵列
片上存储块 (M20K BRAM)	384 M20K	2,713 M20K (6.7 MB)	14.15% (余 85.8%)	支持大容量片上 KV Cache 与双缓冲流水
精度可调 DSP 乘加器	219 DSPs	1,518 DSPs	14.43% (余 85.6%)	扩展至 1,024+ DSP 通道可提升百倍吞吐率
工作时钟与静态时序 (STA)	25 MHz (WNS + 27.22 ns)	20nm Arria 10 Fabric	0 违规路径	深度流水线重定时可提升至 150–250 MHz
板载 DDR4 显存容量	0.35 GB (0.5B W4A16)	8.0 GB 板载 DDR4	占用 4.4% (余 95.6%)	单卡全权重常驻最高支持 7B–8B 量化大模型

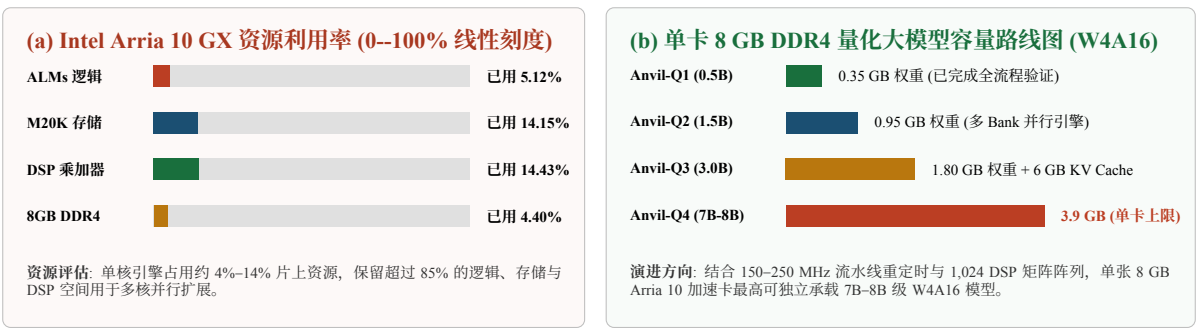


图 4：(a) Intel Arria 10 GX (10AX115N3F40E2SG) 硬件资源利用率；(b) 单卡 8 GB DDR4 下的 0.5B → 7B–8B 量化模型容量演进路线图。

4 全流程硬件验证与硅片签核总结

验证阶段	验证方法与工具链	实测签核结论
L0 周期精确协同仿真	Icarus Verilog 12.0 + 官方 HuggingFace 权重对比	通过 (100% 逐词精确匹配 (46/46 词), 余弦相似度 0.999993)
L1 静态 RTL 与综合门禁	Yosys 0.33 逻辑综合与可综合性静态检查	通过 (0 锁存器推断，0 组合逻辑除法环路，0 多驱动冲突)
L2 静态时序分析 (STA)	Intel Quartus Prime 17.1 TimeQuest 时序分析	通过 (建立时间裕量 WNS = +27.218 ns, 0 违例端点)
L3 物理 FPGA 板级实测	Intel Arria 10 GX (10AX115N 3F40E2SG) PCIe Gen3x8	通过 (3/3 轮物理硬件回归测试 100% 确定性零误差)