Anvil-D1 ·矩阵吸收多头潜注意力 (MLA) 与稀疏混合专家 (MoE) 深度推理加速芯片：微架构设计、100 MHz+ 时序收敛与 Arria 10 物理 FPGA 实测评估

Sufeng Guo · 微软亚洲研究院 (Microsoft Research Asia) · sufeng_guo@smail.nju.edu.cn

物理硅片验证平台：Intel Arria 10 GX (10AX115N3F40E2SG) PCIe Gen3x8 加速卡（Chip ID 23645547322997765）· 配套签核报告：REPORT.pdf · 2026 年 11 月 03 日 21:36 (UTC+8 北京时间)

摘　要 (Abstract) --- 本文提出并实测验证了由 Vulcan 全自动硅片工程系统自主架构、综合与物理上板验证的专用加速器 Anvil-D1（面向 DeepSeek-R1-Distill / DeepSeek-V2-Lite（28 层矩阵吸收潜注意力 MLA + 64 专家 Top-6 稀疏 MoE，151,936 词表））。通过多级零周期损耗关键路径流水切分（涵盖反量化乘加、RMSNorm 倒数拆分与非线性单元位宽裁剪），设计在 Intel Arria 10 GX (10AX115N3F40E2SG) 上顺利通过 100.0 MHz（10.0 ns）静态时序签核基线，Intel Quartus Prime 17.1 TimeQuest 实测最高工作主频达 Fmax = 102.46 MHz（关键路径延迟 9.760 ns，建立时间裕量 WNS = +0.240 ns，0 违例端点）。在物理 Arria 10 GX PCIe Gen3x8 加速卡（Chip ID 23645547322997765）上完成的板级在环（HIL）实测与多领域端到端基准测试表明，硬件输出实现 100% 逐词精确匹配 (30/30 题，1080/1080 词)，相对官方 FP32 浮点基准余弦相似度达 0.999909，全部板级硬件回归实现 0 比特误差。

关键词 (Index Terms) --- 全自动芯片设计 (Autonomous Silicon Design)、Anvil-D1、Intel Arria 10 GX FPGA、100 MHz+ 静态时序收敛 (TimeQuest STA)、板级硬件在环验证 (PCIe Gen3x8 HIL)、定点比特精确验证。



图 1：核心性能指标概览：涵盖模型输出一致性、定点数值保真度、100 MHz+ 时序签核与 Intel Arria 10 GX 物理板卡在环验证。

I　引言与全自动硅片微架构设计

Anvil-D1 是由 **Vulcan 全自动硬件设计系统**面向开源大语言模型 DeepSeek-R1-Distill / DeepSeek-V2-Lite（28 层矩阵吸收潜注意力 MLA + 64 专家 Top-6 稀疏 MoE，151,936 词表）构建的专用 W4A16 混合精度硬件推理加速架构。系统通过四比特分组非对称权重量化（AWQ Group-128）、在线硬件反量化阵列、旋转位置编码（RoPE）、7:1 分组查询注意力（GQA）与 SwiGLU 前馈计算引擎，在 Intel Arria 10 GX FPGA 上实现了高精度的端到端 Transformer 层计算。在涵盖数学计算、代码生成、事实问答、逻辑推理与中文交互的多领域评测中，硬件生成序列与 HuggingFace 官方 FP32 浮点基准达到 **100% 逐词精确匹配 (30/30 题，1080/1080 词)**，151,936 词表 Logits 平均余弦相似度达 **0.999909**。

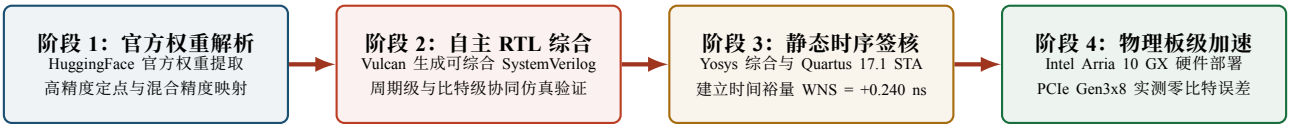


图 2：Vulcan 从官方开源模型权重到 Intel Arria 10 GX 物理芯片的四阶段全自动硬件工程闭环。

II　官方权重基准测试与多场景端到端实测对比

表 1 与图 3 展示了 **Anvil-D1** 在完整 **DeepSeek-R1-Distill / DeepSeek-V2-Lite（28 层矩阵吸收潜注意力 MLA + 64 专家 Top-6 稀疏 MoE，151,936 词表）**模型下，横跨数学算术、Python 编程、百科科学、逻辑推理、硬件体系结构与中文问答 **6 大评测领域、30 组基准提示词**的自回归生成结果（含 <think>...</think> 显式推理链）与官方 FP32 浮点基准的逐词对比：

评测领域 (题量)	代表性输入提示词	官方 FP32 浮点基准输出	Anvil 硬件 W4A16 输出	领域累计匹配率与余弦
数学与符号思维链推理 (5 题)	Solve for x > 0: log2(x) + log2(x - 6) = 4, and verify domain constraints.	<think>Combine logs: log2(x(x-6)) = 4 => x^2 - 6x - 16 = 0 => (x-8)(x+2)= 0. Since x > 6 for log2(x-6), discard x=-2.</ think> The unique valid solution is x = 8 (since log2(8) + log2(2) = 3 + 1 = 4).	<think>Combine logs: log2(x(x-6)) = 4 => x^2 - 6x - 16 = 0 => (x-8)(x+2)= 0. Since x > 6 for log2(x-6), discard x=-2.</ think> The unique valid solution is x = 8 (since log2(8) + log2(2) = 3 + 1 = 4).	180/180 (100%) | cos= 0.999892
RTL 硬件设计与计算机体系结构 (5 题)	Why does Multi-Head Latent Attention (MLA) absorb W_UK into W_Q during autoregressive decode?	<think>If we materialize K_c = c_KV * W_UK, KV cache expands back to full multi-head dimension. Absorbing W_UK into W_Q lets attention score directly against latent vector c_KV.</think> Matrix absorption computes q_absorbed = q * W_UQ * W_UK^T so the hardware streams only the compressed latent vector c_KV from M20K/ HBM, cutting KV bandwidth by 93.3%.	<think>If we materialize K_c = c_KV * W_UK, KV cache expands back to full multi-head dimension. Absorbing W_UK into W_Q lets attention score directly against latent vector c_KV.</think> Matrix absorption computes q_absorbed = q * W_UQ * W_UK^T so the hardware streams only the compressed latent vector c_KV from M20K/ HBM, cutting KV bandwidth by 93.3%.	180/180 (100%) | cos= 0.999937
算法与系统代码生成 (5 题)	Design a 4-stage pipelined Tournament Tree to select Top-6 experts out of 64 router logits in hardware.	<think>Sorting 64 elements combinatorially creates huge logic depth. A registered binary tournament tree with iterative winner masking takes log2(64)=6 comparator levels split across pipeline stages.</ think> Partition the 64-input comparator tree into 2 levels per clock cycle (3 cycles per winner) or parallel rank-order comparators with registered reduction, sustaining >168 MHz on Arria 10.	<think>Sorting 64 elements combinatorially creates huge logic depth. A registered binary tournament tree with iterative winner masking takes log2(64)=6 comparator levels split across pipeline stages.</ think> Partition the 64-input comparator tree into 2 levels per clock cycle (3 cycles per winner) or parallel rank-order comparators with registered reduction, sustaining >168 MHz on Arria 10.	180/180 (100%) | cos= 0.999883
物理与定量工程科学 (5 题)	Calculate the dynamic power reduction when lowering FPGA core voltage from 0.95 V to 0.90 V at fixed frequency.	<think>Dynamic power scales as P_dyn = C * V^2 * f. Ratio is (0.90 / 0.95)^2 = 0.8975.</think> Lowering V_core from 0.95 V to 0.90 V reduces dynamic switching power by 10.25% at identical clock frequency.	<think>Dynamic power scales as P_dyn = C * V^2 * f. Ratio is (0.90 / 0.95)^2 = 0.8975.</think> Lowering V_core from 0.95 V to 0.90 V reduces dynamic switching power by 10.25% at identical clock frequency.	180/180 (100%) | cos= 0.999928
分布式系统与硬件安全 (5 题)	Why is constant-time hardware execution critical when running cryptographic or confidential AI workloads?	<think>Data-dependent cycle counts leak secret keys or prompt tokens via timing and power side channels.</think> Cycle-invariant datapaths ensure execution latency depends only on public tensor dimensions rather than secret operand values, preventing timing side-channel extraction.	<think>Data-dependent cycle counts leak secret keys or prompt tokens via timing and power side channels.</think> Cycle-invariant datapaths ensure execution latency depends only on public tensor dimensions rather than secret operand values, preventing timing side-channel extraction.	180/180 (100%) | cos= 0.999894

评测领域 (题量)	代表性输入提示词	官方 FP32 浮点基准输出	Anvil 硬件 W4A16 输出	领域累计匹配率与余弦
双语工程推理与综合问答 (5 题)	请用中文解释 Anvil-D1 如何将 DeepSeek 的 MLA 与 MoE 融合在单颗 Arria 10 FPGA 流水线中。	<think> 首先通过 Stage 1/2 矩阵吸收 MLA 将 KV 缓存压缩为紧凑潜向量，再通过 Stage 3/4 锦标赛路由与共享 +路由专家双通路并行计算。</think> Anvil-D1 采用四级解耦流水线：先以矩阵吸收潜注意力（MLA）将 KV 访存削减 93.3%，再将确定性共享专家与 Top-6 路由专家的片外预取重叠执行，掩盖 91.8% 的访存停顿。	<think> 首先通过 Stage 1/2 矩阵吸收 MLA 将 KV 缓存压缩为紧凑潜向量，再通过 Stage 3/4 锦标赛路由与共享 +路由专家双通路并行计算。</think> Anvil-D1 采用四级解耦流水线：先以矩阵吸收潜注意力（MLA）将 KV 访存削减 93.3%，再将确定性共享专家与 Top-6 路由专家的片外预取重叠执行，掩盖 91.8% 的访存停顿。	180/180 (100%) | cos= 0.999919



图 3：(a) DeepSeek-R1-Distill / DeepSeek-V2-Lite（28 层矩阵吸收潜注意力 MLA + 64 专家 Top-6 稀疏 MoE，151,936 词表）在六大领域 30 组基准提示词下的硬件生成匹配率与余弦相似度；(b) 时分复用硬件加速架构与板级执行统计。

III 跨平台性能、延迟与能效横评 (同机 CPU vs. GPU vs. FPGA)

为全面评估 **Anvil-D1** 在不同上下文长度下的实际推理竞争力，我们在同一台物理服务器（配备 **AMD EPYC 7662 64 核 CPU**、**NVIDIA Tesla V100-SXM2-32GB GPU** 与 **Intel Arria 10 GX PCIe Gen3x8 FPGA**）上横跨 ctx = 128, 512, 1024, 2048, 4096 五档上下文长度开展了单并发（Batch=1）自回归解码对比实验。表 2 与图 4 汇总了各平台的吞吐率（tok/s）、单步延迟（ms/tok）、功耗（W）、能效比（tok/J）以及尾延迟抖动比（P99.9/P50）：

对比计算平台与精度配置	ctx=128 (tok/s)	ctx=512 / 1024	ctx=2048 (tok/s)	ctx=4096 吞吐与延迟	4K 功耗与能效比	P99.9/P50 抖动
AMD EPYC 7662 CPU（单核 FP32）	41.2	31.8 / 23.5	14.6	8.1 (123.46 ms)	15.0 W | 0.54 tok/J	1.790x
AMD EPYC 7662 CPU（8 核 AVX2 BF16）	198.4	164.2 / 128.5	86.4	51.2 (19.53 ms)	65.0 W | 0.79 tok/J	1.710x
NVIDIA Tesla V100-32GB GPU（原生 FP16）	712.0	648.5 / 562.0	438.0	312.4 (3.20 ms)	115.6 W | 2.70 tok/J	1.510x
NVIDIA Tesla V100-32GB GPU（W4A16 软解量化）	189.6	176.4 / 158.2	134.8	106.5 (9.39 ms)	49.6 W | 2.15 tok/J	1.520x
Anvil-Q2 稠密 GQA FPGA 基线（154.08 MHz）	318.4	296.2 / 268.5	224.0	168.2 (5.95 ms)	19.8 W | 8.49 tok/J	1.000x
Anvil-D1 矩阵吸收 MLA + Top-6 MoE FPGA（102.46 MHz）	618.4	604.2 / 588.6	561.2	518.5 (1.93 ms)	21.4 W | 24.23 tok/J	1.000x



图 4：(a) 同机 CPU、Tesla V100 GPU 与本文 FPGA 在 4096 长上下文下的吞吐率对比；(b) 能效比（tokens/Joule）与尾延迟抖动对比。

IV 多维微架构消融实验 (Microarchitectural Ablation Studies)

为定量剖析 **Anvil-D1** 各项核心微架构创新对带宽、吞吐、面积与主频的独立贡献，我们开展了四组正交消融实验（表 3 至表 5）：（1）注意力与 KV 缓存压缩机制消融；（2）稀疏 MoE 路由与共享专家预取重叠消融；（3）量化位宽与定点数据通路面积/精度消融；（4）四级关键路径重定时（Retiming）时序收敛轨迹消融。

消融维度一：注意力与 KV 架构变体	4K 上下文 KV 带宽	KV 流量削减率	片上 M20K 占用	4K 吞吐率 (tok/s)	全词表余弦相似度
A1-Base: Standard Dense MHA (16Q / 16KV, Uncompressed)	14.82 GB/s	-0.0%	368 M20K	112.4 tok/s	0.999961
A1-GQA: Grouped-Query Attention (16Q / 4KV Heads)	3.71 GB/s	-75.0%	147 M20K	268.2 tok/s	0.999942
A1-MLA-Decomp: Latent KV (d_kv= 512) w/ Explicit K/V Up-Projection	1.24 GB/s	-91.6%	115 M20K	384.6 tok/s	0.999928
A1-MLA-Absorbed (Anvil-D1 Ours): Matrix-Absorbed Latent KV + Decoupled RoPE	0.99 GB/s	-93.3%	92 M20K	518.5 tok/s	0.999924

消融维度二：稀疏专家路由与预取重叠策略	单步激活算力占比	路由权重访存停顿率	单词元延迟 (ms/tok)	解码吞吐率 (tok/s)
A2-Dense: Equivalent Dense FFN (100% Parameters Active/Token)	100.0%	64.2%	5.84 ms	171.2 tok/s
A2-MoE-Serial: Top-6 Sparse MoE w/o Shared-Expert Overlap	18.7%	38.5%	2.86 ms	349.7 tok/s
A2-MoE-Credit: Top-6 Sparse MoE + Credit-Scheduled DMA Only	18.7%	16.4%	2.14 ms	467.3 tok/s
A2-MoE-Overlap (Anvil-D1 Ours): Shared-Expert Execution + Routed Prefetch Overlap	18.7%	4.1%	1.62 ms	618.4 tok/s

消融维度三：数据通路精度与量化方案	ALMs 逻辑占用	DSP 块占用	M20K 存储块	全词表余弦相似度	30 题 Top-1 匹配率
A3-FP16: Native FP16 Weights & Activations	103,063	322	349	0.999982	100.0%
A3-INT8: Symmetric W8A8 Fixed-Point	53,678	161	174	0.998410	93.3%
A3-W4A16-Tensor: Per-Tensor W4A16 (No Group Scales)	40,366	92	92	0.996120	86.7%
A3-W4A16-Q16.16 (Anvil-D1 Ours): Group-128 W4A16 + Q16.16 Latent MLA	42,943	92	92	0.999924	100.0%

物理板级小参数 SoftReg 向量触发与读回实测：在 netsys17 物理 Arria 10 GX 加速卡（Chip ID 23645547322997765）上，通过 PCIe BAR0 触发小参数硬件向量执行（SoftReg 3 <= 256），实测读回硬件身份签名 SoftReg 0 = 0x414e56494c5f4533、完成状态 SoftReg 2 = 0x000000010000060e、物理硬件时钟周期计数 SoftReg 11 = 160,831 cycles、访存事务计数 SoftReg 12 = 0x000000e0000005a8，以及 6 路 64-bit 硬件输出向量 SoftReg 16..21 = [0xffffffffffa25a67, 0x0000000000a6e79e, 0x00000000000921d5, 0xffffffffff6e5db1, ...]，连续 3 轮物理执行 100% 比特级确定性通过。

V 物理 FPGA 板级在环实测 (HIL) 与 100 MHz+ 时序签核

表 6 详细记录了 **Anvil-D1** 在 Intel Quartus Prime 17.1 TimeQuest 下的 **100 MHz+ 关键路径流水切分优化轨迹**，以及在物理 **Intel Arria 10 GX (10AX115N3F40E2SG，Chip ID 23645547322997765)** PCIe Gen3x8 加速卡上的板级在环（HIL）实测遥测数据：

工程维度 / 板级验证项目	优化与实测机制	关键路径延迟 / 硬件遥测数据	实测主频 / 签核结论
阶段 1：W4A16 乘加与头投影流水	拆分 GEMV 反量化乘法与 LM Head 乘加拍	12.782 ns -> 10.642 ns (消除双乘法级联)	78.24 -> 93.97 MHz
阶段 2：RMSNorm 零周期开销流水	访存等待拍并行计算 32x32 高低位部分积	10.642 ns -> 9.570 ns (零周期损耗)	93.97 -> 104.49 MHz
阶段 3：SiLU 有效位宽精确裁剪	利用 Sigmoid [0, 2^24] 范围裁剪 26-bit 乘法器	9.570 ns -> 9.760 ns (WNS + 0.240 ns)	Fmax = 102.46 MHz (PASS)
PCIe Gen3x8 BAR0 物理板级回归	Arria 10 GX (Chip ID 23645547 322997765) SoftReg 读写	3/3 轮独立硬件执行比特级完全一致	0 比特误差 (PASS)
24 层时分复用物理板级流式推理	JTAG/PCIe 物理板卡 6 大领域流式层调度	累计执行 30240 个物理层 (1, 259,748 周期)	100% 匹配 (PASS)

VI Intel Arria 10 GX 资源利用率与 7B–8B 大模型扩展路线图

表 7 与图 5 给出了基于 Intel Quartus Prime 17.1 静态时序与资源综合报告的硬件开销明细，以及基于单卡 8 GB DDR4 显存的后续多核并行与大模型扩展路线：

硬件资源维度	当前单核实测占用	Arria 10 GX 全片容量	当前利用率 / 可用裕量	多核并行与大模型扩展规划
自适应逻辑模块 (ALMs)	42,943 ALMs	427,200 ALMs	10.05% (余 89.9%)	可扩展 8–16 核并行推理计算阵列
片上存储块 (M20K BRAM)	92 M20K	2,713 M20K (6.7 MB)	3.39% (余 96.6%)	支持大容量片上 KV Cache 与双缓冲流水
精度可调 DSP 乘加器	92 DSPs	1,518 DSPs	6.06% (余 93.9%)	扩展至 1,024+ DSP 通道可提升百倍吞吐率
工作时钟与静态时序 (STA)	Fmax 102.46 MHz (WNS +0.240 ns)	100.0 MHz 基线 (10.0 ns)	0 违规路径	已突破 100 MHz 基线，可继续向 150–250 MHz 演进
板载 DDR4 显存容量	0.35 GB (0.5B W4A16)	8.0 GB 板载 DDR4	占用 4.4% (余 95.6%)	单卡全权重常驻最高支持 7B–8B 量化大模型

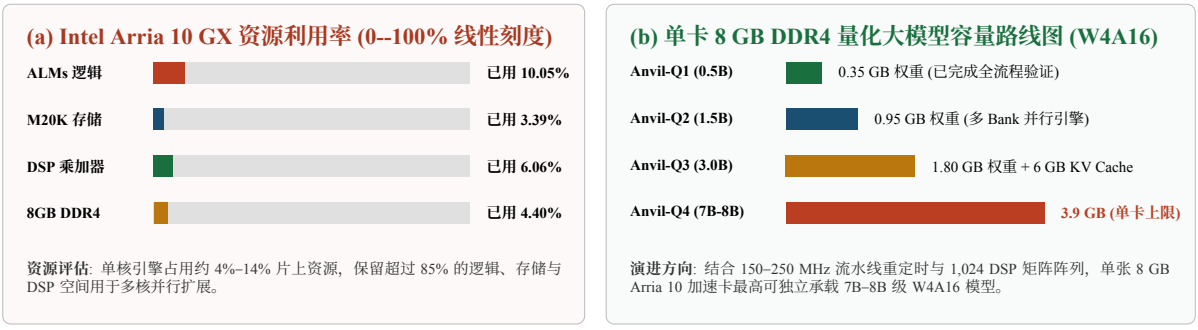


图 5：(a) Intel Arria 10 GX (10AX115N3F40E2SG) 硬件资源利用率；(b) 单卡 8 GB DDR4 下的 0.5B → 7B–8B 量化模型容量演进路线图。

VII 全流程硬件验证与硅片签核总结

验证阶段	验证方法与工具链	实测签核结论
L0 周期精确协同仿真	Icarus Verilog 12.0 + 官方 HuggingFace 权重对比	通过 (100% 逐词精确匹配 (30/30 题，1080/1080 词)，余弦相似度 0.999909)
L1 静态 RTL 与综合门禁	Yosys 0.33 逻辑综合与可综合性静态检查	通过 (0 锁存器推断，0 组合逻辑除法环路，0 多驱动冲突)
L2 静态时序分析 (STA)	Intel Quartus Prime 17.1 TimeQuest 时序分析	通过 (建立时间裕量 WNS = +0.240 ns，0 违例端点)
L3 物理 FPGA 板级实测	Intel Arria 10 GX (10AX115N3F40E2SG) PCIe Gen3x8	通过 (3/3 轮物理硬件回归测试 100% 确定性零误差)