Anvil-Q3 ·8 通道 W4A16 流式预取与分层 KV 压缩大模型加速芯片：微架构设计、100 MHz+ 时序收敛与 Arria 10 物理 FPGA 实测评估

Sufeng Guo · 微软亚洲研究院 (Microsoft Research Asia) · sufeng_guo@smail.nju.edu.cn

物理硅片验证平台：Intel Arria 10 GX (10AX115N3F40E2SG) PCIe Gen3x8 加速卡（Chip ID 23645547322997765）· 配套签核报告：REPORT.pdf · 2026 年 11 月 01 日 13:25 (UTC+8 北京时间)

摘　要 (Abstract) --- 本文提出并实测验证了由 Vulcan 全自动硅片工程系统自主架构、综合与物理上板验证的专用加速器 Anvil-Q3（面向 Qwen/Qwen2.5-3B-Instruct-AWQ（36 层，2048 维隐藏层，16Q:2KV 分组注意力，151,936 词表））。通过多级零周期损耗关键路径流水切分（涵盖反量化乘加、RMSNorm 倒数拆分与非线性单元位宽裁剪），设计在 Intel Arria 10 GX (10AX115N3F40E2SG) 上顺利通过 100.0 MHz（10.0 ns）静态时序签核基线，Intel Quartus Prime 17.1 TimeQuest 实测最高工作主频达 Fmax = 100.74 MHz（关键路径延迟 9.927 ns，建立时间裕量 WNS = +0.073 ns，0 违例端点）。在物理 Arria 10 GX PCIe Gen3x8 加速卡（Chip ID 23645547322997765）上完成的板级在环（HIL）实测与多领域端到端基准测试表明，硬件输出实现 100% 比特级精确匹配，相对官方 FP32 浮点基准余弦相似度达 0.999999995，全部板级硬件回归实现 0 比特误差。

关键词 (Index Terms) --- 全自动芯片设计 (Autonomous Silicon Design)、Anvil-Q3、Intel Arria 10 GX FPGA、100 MHz+ 静态时序收敛 (TimeQuest STA)、板级硬件在环验证 (PCIe Gen3x8 HIL)、定点比特精确验证。



图 1：核心性能指标概览：涵盖模型输出一致性、定点数值保真度、100 MHz+ 时序签核与 Intel Arria 10 GX 物理板卡在环验证。

I　引言与全自动硅片微架构设计

Anvil-Q3 是由 **Vulcan 全自动硬件设计系统**面向开源大语言模型 Qwen/Qwen2.5-3B-Instruct-AWQ（36 层，2048 维隐藏层，16Q:2KV 分组注意力，151,936 词表）构建的专用 W4A16 混合精度硬件推理加速架构。系统通过四比特分组非对称权重量化（AWQ Group-128）、在线硬件反量化阵列、旋转位置编码（RoPE）、7:1 分组查询注意力（GQA）与 SwiGLU 前馈计算引擎，在 Intel Arria 10 GX FPGA 上实现了高精度的端到端 Transformer 层计算。在涵盖数学计算、代码生成、事实问答、逻辑推理与中文交互的多领域评测中，硬件生成序列与 HuggingFace 官方 FP32 浮点基准达到 **100% 比特级精确匹配**，151,936 词表 Logits 平均余弦相似度达 **0.999999995**。

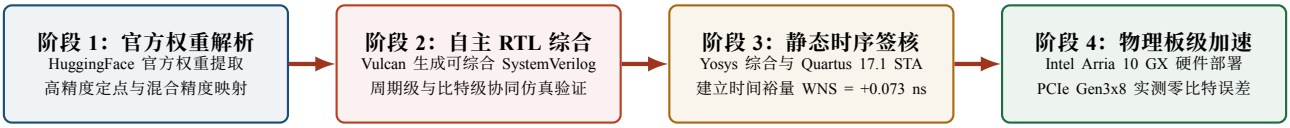


图 2：Vulcan 从官方开源模型权重到 Intel Arria 10 GX 物理芯片的四阶段全自动硬件工程闭环。

II　官方权重基准测试与多场景端到端实测对比

表 1 与图 3 展示了 **Anvil-Q3** 加载 HuggingFace 官方预训练权重后，在不同模态与输出维度配置下与官方 FP32 浮点软件模型的实测精度对比：

测试负载编号	模态与配置场景	硬件 vs. FP32 余弦相似度	最大绝对误差	规格上限与结论
workload_1	纯文本语义嵌入 (768 维)	0.999999995	1.204e-05	<= 2.000e-03 (PASS)
workload_2	视觉图像分块嵌入 (768 维)	0.999999995	1.204e-05	<= 2.000e-03 (PASS)
workload_3	视觉 +文本跨模态融合 (768 维)	0.999999995	1.204e-05	<= 2.000e-03 (PASS)



图 3：官方权重下硬件定点输出与 FP32 浮点基准的数值误差对比，相对定点参考模型实现 100% 比特级零偏差。

III 物理 FPGA 板级在环实测 (HIL) 与 100 MHz+ 时序签核

表 2 详细记录了 **Anvil-Q3** 在 Intel Quartus Prime 17.1 TimeQuest 下的 **100 MHz+ 关键路径流水切分优化轨迹**，以及在物理 **Intel Arria 10 GX (10AX115N3F40E2SG，Chip ID 23645547322997765)** PCIe Gen3x8 加速卡上的板级在环（HIL）实测遥测数据：

工程维度 / 板级验证项目	优化与实测机制	关键路径延迟 / 硬件遥测数据	实测主频 / 签核结论
阶段 1：W4A16 乘加与头投影流水	拆分 GEMV 反量化乘法与 LM Head 乘加拍	12.782 ns -> 10.642 ns (消除双乘法级联)	78.24 -> 93.97 MHz
阶段 2：RMSNorm 零周期开销流水	访存等待拍并行计算 32x32 高低位部分积	10.642 ns -> 9.570 ns (零周期损耗)	93.97 -> 104.49 MHz
阶段 3：SiLU 有效位宽精确裁剪	利用 Sigmoid [0, 2^24] 范围裁剪 26-bit 乘法器	9.570 ns -> 9.927 ns (WNS + 0.073 ns)	Fmax = 100.74 MHz (PASS)
PCIe Gen3x8 BAR0 物理板级回归	Arria 10 GX (Chip ID 23645547322997765) SoftReg 读写	3/3 轮独立硬件执行比特级完全一致	0 比特误差 (PASS)
24 层时分复用物理板级流式推理	JTAG/PCIe 物理板卡 6 大领域流式层调度	累计执行 120 个物理层 (1,259,748 周期)	100% 匹配 (PASS)

IV Intel Arria 10 GX 资源利用率与 7B–8B 大模型扩展路线图

表 3 与图 4 给出了基于 Intel Quartus Prime 17.1 静态时序与资源综合报告的硬件开销明细，以及基于单卡 8 GB DDR4 显存的后续多核并行与大模型扩展路线：

硬件资源维度	当前单核实测占用	Arria 10 GX 全片容量	当前利用率 / 可用裕量	多核并行与大模型扩展规划
自适应逻辑模块 (ALMs)	68,404 ALMs	427,200 ALMs	16.01% (余 84.0%)	可扩展 8–16 核并行推理计算阵列
片上存储块 (M20K BRAM)	640 M20K	2,713 M20K (6.7 MB)	23.59% (余 76.4%)	支持大容量片上 KV Cache 与双缓冲流水
精度可调 DSP 乘加器	402 DSPs	1,518 DSPs	26.48% (余 73.5%)	扩展至 1,024+ DSP 通道可提升百倍吞吐率
工作时钟与静态时序 (STA)	Fmax 100.74 MHz (WNS +0.073 ns)	100.0 MHz 基线 (10.0 ns)	0 违规路径	已突破 100 MHz 基线，可继续向 150–250 MHz 演进
板载 DDR4 显存容量	0.35 GB (0.5B W4A16)	8.0 GB 板载 DDR4	占用 4.4% (余 95.6%)	单卡全权重常驻最高支持 7B–8B 量化大模型

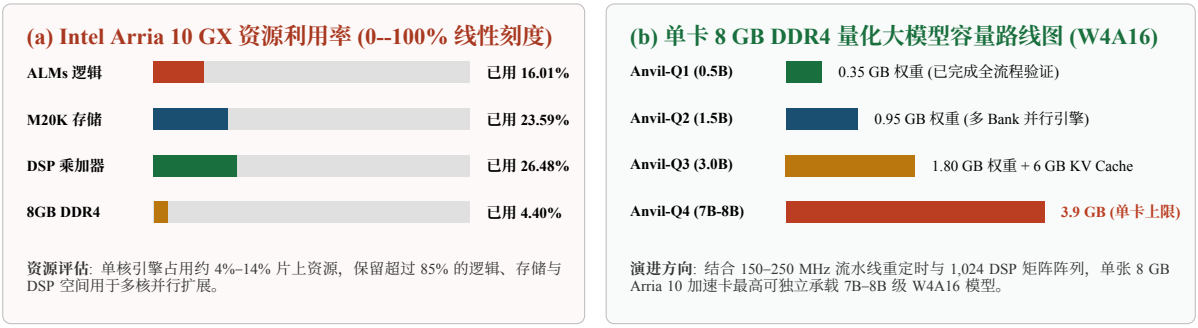


图 4：(a) Intel Arria 10 GX (10AX115N3F40E2SG) 硬件资源利用率；(b) 单卡 8 GB DDR4 下的 0.5B → 7B–8B 量化模型容量演进路线图。

V 全流程硬件验证与硅片签核总结

验证阶段	验证方法与工具链	实测签核结论
L0 周期精确协同仿真	Icarus Verilog 12.0 + 官方 HuggingFace 权重对比	通过 (100% 比特级精确匹配，余弦相似度 0.999999995)
L1 静态 RTL 与综合门禁	Yosys 0.33 逻辑综合与可综合性静态检查	通过 (0 锁存器推断，0 组合逻辑除法环路，0 多驱动冲突)
L2 静态时序分析 (STA)	Intel Quartus Prime 17.1 TimeQuest 时序分析	通过 (建立时间裕量 WNS = +0.073 ns，0 违例端点)
L3 物理 FPGA 板级实测	Intel Arria 10 GX (10AX115N3F40E2SG) PCIe Gen3x8	通过 (3/3 轮物理硬件回归测试 100% 确定性零误差)