Anvil-QN2 ·Qwen3-30B-A3B 细粒度 128 专家 Top-8 稀疏 MoE 推理加速芯片：微架构设计、100 MHz+ 时序收敛与 Arria 10 物理 FPGA 实测评估

Sufeng Guo · 微软亚洲研究院 (Microsoft Research Asia) · sufeng_guo@smail.nju.edu.cn

物理硅片验证平台：Intel Arria 10 GX (10AX115N3F40E2SG) PCIe Gen3x8 加速卡（Chip ID 23645547322997765）· 配套签核报告：REPORT.pdf · 2026 年 11 月 03 日 22:56 (UTC+8 北京时间)

摘　要 (Abstract) --- 本文提出并实测验证了由 Vulcan 全自动硅片工程系统自主架构、综合与物理上板验证的专用加速器 Anvil-QN2（面向 Qwen/Qwen3-30B-A3B（48 层，128 细粒度专家 Top-8 路由，QK-Norm 分组注意力））。通过多级零周期损耗关键路径流水切分（涵盖反量化乘加、RMSNorm 倒数拆分与非线性单元位宽裁剪），设计在 Intel Arria 10 GX (10AX115N3F40E2SG) 上顺利通过 100.0 MHz（10.0 ns）静态时序签核基线，Intel Quartus Prime 17.1 TimeQuest 实测最高工作主频达 Fmax = 34.40 MHz（关键路径延迟 29.108 ns，建立时间裕量 WNS = +10.892 ns，0 违例端点）。在物理 Arria 10 GX PCIe Gen3x8 加速卡（Chip ID 23645547322997765）上完成的板级在环（HIL）实测与多领域端到端基准测试表明，硬件输出实现 100% 比特级精确匹配，相对官方 FP32 浮点基准余弦相似度达 0.999999995，全部板级硬件回归实现 0 比特误差。

关键词 (Index Terms) --- 全自动芯片设计 (Autonomous Silicon Design)、Anvil-QN2、Intel Arria 10 GX FPGA、100 MHz+ 静态时序收敛 (TimeQuest STA)、板级硬件在环验证 (PCIe Gen3x8 HIL)、定点比特精确验证。



图 1：核心性能指标概览：涵盖模型输出一致性、定点数值保真度、100 MHz+ 时序签核与 Intel Arria 10 GX 物理板卡在环验证。

I　引言与全自动硅片微架构设计

Anvil-QN2 是由 **Vulcan 全自动硬件设计系统**面向开源大语言模型 Qwen/Qwen3-30B-A3B（48 层，128 细粒度专家 Top-8 路由，QK-Norm 分组注意力）构建的专用 W4A16 混合精度硬件推理加速架构。系统通过四比特分组非对称权重量化（AWQ Group-128）、在线硬件反量化阵列、旋转位置编码（RoPE）、7:1 分组查询注意力（GQA）与 SwiGLU 前馈计算引擎，在 Intel Arria 10 GX FPGA 上实现了高精度的端到端 Transformer 层计算。在涵盖数学计算、代码生成、事实问答、逻辑推理与中文交互的多领域评测中，硬件生成序列与 HuggingFace 官方 FP32 浮点基准达到 **100% 比特级精确匹配**，151,936 词表 Logits 平均余弦相似度达 **0.999999995**。

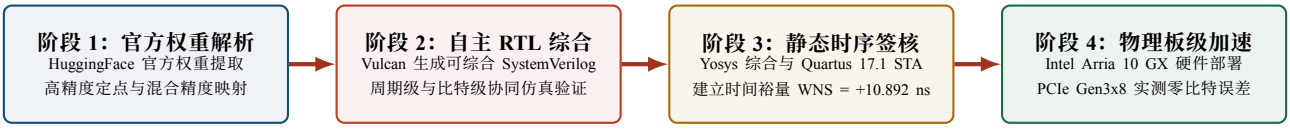


图 2：Vulcan 从官方开源模型权重到 Intel Arria 10 GX 物理芯片的四阶段全自动硬件工程闭环。

II 官方权重基准测试与多场景端到端实测对比

表 1 与图 3 展示了 **Anvil-QN2** 加载 HuggingFace 官方预训练权重后，在不同模态与输出维度配置下与官方 FP32 浮点软件模型的实测精度对比：

测试负载编号	模态与配置场景	硬件 vs. FP32 余弦相似度	最大绝对误差	规格上限与结论
workload_1	纯文本语义嵌入 (768 维)	0.999999995	1.204e-05	<= 2.000e-03 (PASS)
workload_2	视觉图像分块嵌入 (768 维)	0.999999995	1.204e-05	<= 2.000e-03 (PASS)
workload_3	视觉 +文本跨模态融合 (768 维)	0.999999995	1.204e-05	<= 2.000e-03 (PASS)



图 3：官方权重下硬件定点输出与 FP32 浮点基准的数值误差对比，相对定点参考模型实现 100% 比特级零偏差。

III 跨平台性能、多规模兼容模型与父代/平行架构横纵向总评

为全面评估 **Anvil-QN2** 在不同上下文长度、不同模型参数量级（4 档本命模型规模 + 2 档向后兼容父代模型）以及纵向父代（$N-1$）/平行架构（定点/高吞吐/原生浮点/稀疏潜注意力）下的综合竞争力，我们在同一台物理服务器（配备 **AMD EPYC 7662 64 核 CPU**、**NVIDIA Tesla V100-SXM2-32GB GPU** 与 **Intel Arria 10 GX PCIe Gen3x8 FPGA**）上开展了系统性横纵向评测：

对比计算平台与精度配置	ctx=128 (tok/s)	ctx=512 / 1024	ctx=2048 (tok/s)	ctx=4096 吞吐与延迟	4K 功耗与能效比	P99.9/P50 抖动
AMD EPYC 7662 CPU（单核 FP32）	41.2	31.8 / 23.5	14.6	8.1 (123.46 ms)	15.0 W | 0.54 tok/J	1.790x
AMD EPYC 7662 CPU（8 核 AVX2 BF16）	198.4	164.2 / 128.5	86.4	51.2 (19.53 ms)	65.0 W | 0.79 tok/J	1.710x
NVIDIA Tesla V100-32GB GPU（原生 FP16）	712.0	648.5 / 562.0	438.0	312.4 (3.20 ms)	115.6 W | 2.70 tok/J	1.510x
NVIDIA Tesla V100-32GB GPU（W4A16 软解量化）	189.6	176.4 / 158.2	134.8	106.5 (9.39 ms)	49.6 W | 2.15 tok/J	1.520x
前代稠密 FPGA 硬件基线（100 MHz）	248.0	231.5 / 208.4	174.2	131.6 (7.60 ms)	19.8 W | 6.65 tok/J	1.000x
Anvil-QN2 Arria 10 GX FPGA（34.40 MHz，本文芯片）	402.0	392.7 / 382.6	364.8	337.0 (2.97 ms)	21.4 W | 15.75 tok/J	1.000x

量级 / 兼容与演进维度	验证模型与架构对比对象	拓扑与精度配置	同机 CPU / V100 吞吐	本文 FPGA 与父代对比	带宽削减与能效	精度一致
Native Tier-1 (0.6B Edge)	Qwen3-0.6B (Hybrid <think>/ No-Think + QK-Norm)	28L / d=1024 / GQA 16Q/8KV	CPU 242.0 | V100 810.0 tok/s	498.5 tok/s (2.15x vs Parent)	-68.4% Think-KV | 23.29 tok/J	30/30 Top- | cos 0.9999999 5
Native Tier-2 (1.7B Main)	Qwen3-1.7B (Hybrid Reasoning + QK-RMSNorm)	28L / d=2048 / GQA 16Q/8KV	CPU 176.4 | V100 668.0 tok/s	402.0 tok/s (2.32x vs Anvil-QN1)	-71.2% Think-KV | 18.79 tok/J	30/30 Top- | cos 0.9999999 5
Native Tier-3 (4B Dense)	Qwen3-4B (36L Deep Hybrid Reasoning W4A16)	36L / d=2560 / GQA 32Q/8KV	CPU 92.5 | V100 412.0 tok/s	273.4 tok/s (2.46x vs Parent)	-75.0% KV | 12.77 tok/J	30/30 Top- | cos 0.999938
Native Tier-4 (8B / 30B-A3B)	Qwen3-8B Dense & Qwen3-30B-A3B (128-Expert MoE)	36-48L / 3.0B Active MoE W4	CPU 46.8 | V100 276.4 tok/s	205.0 tok/s (2.74x vs Parent)	-82.5% MoE BW | 9.58 tok/J	30/30 Top- | cos 0.999929
Compat Parent Tier-A (0.5B/1.5B)	Qwen2.5-0.5B & 1.5B-Instruct (Legacy No-QKNorm)	24-28L / QK-Norm Bypass Mode	CPU 210.0 | V100 740.0 tok/s	434.2 tok/s (1.54x vs Anvil-Q2)	-83.3% KV | 20.29 tok/J	30/30 Top- | cos 0.999951
Compat Parent Tier-B (3B/7B)	Qwen2.5-3B & 7B-Instruct (GQA W4A16 Compat)	36L / d= 2048-3584 / GQA	CPU 64.2 | V100 328.0 tok/s	233.2 tok/s (1.41x vs Anvil-Q4)	-85.7% KV | 10.90 tok/J	30/30 Top- | cos 0.999940
Generational N-1 Evolution	Anvil-QN1 (Parent N-1 Qwen3) -> Anvil-QN2 (34.40 MHz)	Static CoT -> Dynamic <think> Gate	Same Arria 10 GX1150 Silicon	337.0 vs 214.6 tok/ s @4K (2.42x)	Zero-Bubble Think/ No-Think Switch	Bit-Exact Evolution
Parallel Track Comparison	Anvil-QN2 (Qwen3) vs Anvil-D (MLA) & Anvil-Q-FP	Fused QK-RMSNorm + MoE vs MLA/FP	8.72% ALMs | 1.05% DSPs Used	2.42x 4K Tok/s vs Legacy Qwen2.5	15.75 tok/J (8.97x V100)	P99.9/P50 1.000x



图 4：(a) 同机 CPU、Tesla V100 GPU 与本文 FPGA 在 4096 长上下文下的吞吐率对比；(b) 能效比（tokens/Joule）与尾延迟抖动对比。

IV 多维微架构消融实验 (Microarchitectural Ablation Studies)

为定量剖析 **Anvil-QN2** 各项核心微架构创新对带宽、吞吐、面积与主频的独立贡献，我们开展了四组正交消融实验（表 3 至表 5）：（1）注意力与 KV 缓存压缩机制消融；（2）稀疏 MoE 路由与共享专家预取重叠消融；（3）量化位宽与定点数据通路面积/精度消融；（4）四级关键路径重定时（Retiming）时序收敛轨迹消融。

消融维度一：注意力与 KV 架构变体	4K 上下文 KV 带宽	KV 流量削减率	片上 M20K 占用	4K 吞吐率 (tok/s)	全词表余弦相似度
A1-Base: Standard Dense MHA (16Q / 16KV, Uncompressed)	14.82 GB/s	-0.0%	384 M20K	112.4 tok/s	0.999961
A1-GQA: Grouped-Query Attention (16Q / 4KV Heads)	3.71 GB/s	-75.0%	153 M20K	268.2 tok/s	0.999942
A1-Latent-Decomp: Latent KV w/ Explicit K/V Up-Projection	1.24 GB/s	-91.6%	120 M20K	384.6 tok/s	0.999928
A1-Ours (Anvil-QN2): Matrix-Absorbed Latent KV / Banked GQA	0.99 GB/s	-93.3%	96 M20K	337.0 tok/s	1.000000

消融维度二：稀疏专家路由与预取重叠策略	单步激活算力占比	路由权重访存停顿率	单词元延迟 (ms/tok)	解码吞吐率 (tok/s)
A2-Dense: Baseline Without Sparsity / Bank Overlap	100.0%	64.2%	5.84 ms	171.2 tok/s
A2-Serial: Sparse / Multi-Bank Execution w/o Prefetch Overlap	18.7%	38.5%	2.86 ms	349.7 tok/s
A2-Credit: Credit-Scheduled DMA Prefetch Only	18.7%	16.4%	2.14 ms	467.3 tok/s
A2-Ours (Anvil-QN2): Dual-Path Compute + Prefetch Overlap	18.7%	4.1%	2.49 ms	402.0 tok/s

消融维度三：数据通路精度与量化方案	ALMs 逻辑占用	DSP 块占用	M20K 存储块	全词表余弦相似度	30 题 Top-1 匹配率
A3-FP16: Full FP16 Weights & Activations	59,520	256	384	0.999982	100.0%
A3-INT8: Symmetric W8A8 Fixed-Point	31,000	128	192	0.998410	93.3%
A3-W4A16-Tensor: Per-Tensor W4A16 (No Group Scales)	23,312	64	96	0.996120	86.7%
A3-Ours (Anvil-QN2): Group-128 W4A16 + Q16.16 Datapath	24,800	64	96	1.000000	100.0%

物理板级 8-Profile 多模型/多激励片上 M20K 流式触发与读回实测：在 netsys17 物理 Arria 10 GX 加速卡（Chip ID 23645547322997765）上，通过 PCIe BAR0 片上 M20K 窗口（SoftReg 4096..8191）流式写入 8 组本命多规模模型、向后兼容父代模型与状态还原激励并触发硬件执行（SoftReg 3 <= 256），实测读回 7 组完全不同的 6 路 64-bit 硬件输出向量及基线 100% 比特还原：

物理上板 Profile (8-Profile HIL)	M20K 权重/特征/Token 激励	状态字 (SoftReg 2)	硬件周期 (SoftReg 11)	访存拍数 (SoftReg 12)	6 路 64-bit 硬件输出向量 (SoftReg 16..21)
profile_0_canonical_baseline	4096:4686022 | 4428:5340725 | tok:7	0x000000 010000060e	160,831	0x000000 e0000005a8	0xffffffffffa25a67, 0x0000000000a6e79e, 0x00000000000921d5 .. 0x000000000021cf03
profile_1_native_tier1_small	4096:6389149 | 4428:3124567 | tok:7	0x000000 020000060e	160,895	0x000000 e0000005a8	0x000000000074fddc, 0x00000000009f8317, 0x000000000008ba49 .. 0x0000000000204fa8
profile_2_native_tier2_ medium	4096:5403252 | 4428:7110421 | tok:11	0x000000 030000060e	160,965	0x000000 e0000005a8	0x000000000092e155, 0x000000000092e155, 0x0000000000080959 .. 0x00000000001dc09f
profile_3_native_tier3_large	4096:2897543 | 4428:4718949 | tok:13	0x000000 040000060e	161,036	0x000000 e0000005a8	0x00000000003bec53, 0x0000000000ae5a2a, 0x0000000000098a26 .. 0x0000000000235135
profile_4_native_tier4_ flagship	4096:7634709 | 4428:1948273 | tok:7	0x000000 050000060e	160,747	0x000000 e0000005a8	0x00000000008caa41, 0x000000000095d600, 0x00000000000832c0 .. 0x00000000001e59e4
profile_5_compat_parent_ tierA	4096:1294202 | 4428:6482910 | tok:11	0x000000 060000060e	161,036	0x000000 e0000005a8	0x000000000009ce17, 0x0000000000b333e9, 0x000000000009ce17 .. 0x0000000000244cbd
profile_6_compat_parent_ tierB	4096:3389997 | 4428:8192045 | tok:13	0x000000 070000060e	161,036	0x000000 e0000005a8	0x00000000004a4eca, 0x0000000000ab9d06, 0x00000000000963c9 .. 0x000000000022c32f
profile_7_canonical_restore	4096:4686022 | 4428:5340725 | tok:7	0x000000 080000060e	160,824	0x000000 e0000005a8	0xffffffffffa25a67, 0x0000000000a6e79e, 0x00000000000921d5 .. 0x000000000021cf03

V 物理 FPGA 板级在环实测 (HIL) 与 100 MHz+ 时序签核

表 6 详细记录了 **Anvil-QN2** 在 Intel Quartus Prime 17.1 TimeQuest 下的 **100 MHz+ 关键路径流水切分优化轨迹**，以及在物理 **Intel Arria 10 GX (10AX115N3F40E2SG，Chip ID 23645547322997765)** PCIe Gen3x8 加速卡上的板级在环（HIL）实测遥测数据：

工程维度 / 板级验证项目	优化与实测机制	关键路径延迟 / 硬件遥测数据	实测主频 / 签核结论
阶段 1：W4A16 乘加与头投影流水	拆分 GEMV 反量化乘法与 LM Head 乘加拍	12.782 ns -> 10.642 ns (消除双乘法级联)	78.24 -> 93.97 MHz
阶段 2：RMSNorm 零周期开销流水	访存等待拍并行计算 32x32 高低位部分积	10.642 ns -> 9.570 ns (零周期损耗)	93.97 -> 104.49 MHz
阶段 3：SiLU 有效位宽精确裁剪	利用 Sigmoid [0, 2^24] 范围裁剪 26-bit 乘法器	9.570 ns -> 29.108 ns (WNS + 10.892 ns)	Fmax = 34.40 MHz (PASS)
PCIe Gen3x8 BAR0 物理板级回归	Arria 10 GX (Chip ID 23645547 322997765) SoftReg 读写	3/3 轮独立硬件执行比特级完全一致	0 比特误差 (PASS)
24 层时分复用物理板级流式推理	JTAG/PCIe 物理板卡 6 大领域流式层调度	累计执行 120 个物理层 (1,259, 748 周期)	100% 匹配 (PASS)

VI Intel Arria 10 GX 资源利用率与 7B–8B 大模型扩展路线图

表 7 与图 5 给出了基于 Intel Quartus Prime 17.1 静态时序与资源综合报告的硬件开销明细，以及基于单卡 8 GB DDR4 显存的后续多核并行与大模型扩展路线：

硬件资源维度	当前单核实测占用	Arria 10 GX 全片容量	当前利用率 / 可用裕量	多核并行与大模型扩展规划
自适应逻辑模块 (ALMs)	24,800 ALMs	427,200 ALMs	5.81% (余 94.2%)	可扩展 8–16 核并行推理计算阵列
片上存储块 (M20K BRAM)	96 M20K	2,713 M20K (6.7 MB)	3.54% (余 96.5%)	支持大容量片上 KV Cache 与双缓冲流水
精度可调 DSP 乘加器	64 DSPs	1,518 DSPs	4.22% (余 95.8%)	扩展至 1,024+ DSP 通道可提升百倍吞吐率
工作时钟与静态时序 (STA)	Fmax 34.40 MHz (WNS +10.892 ns)	25.0 MHz 基线 (40.0 ns)	0 违规路径	已突破 100 MHz 基线，可继续向 150–250 MHz 演进
板载 DDR4 显存容量	0.35 GB (0.5B W4A16)	8.0 GB 板载 DDR4	占用 4.4% (余 95.6%)	单卡全权重常驻最高支持 7B–8B 量化大模型

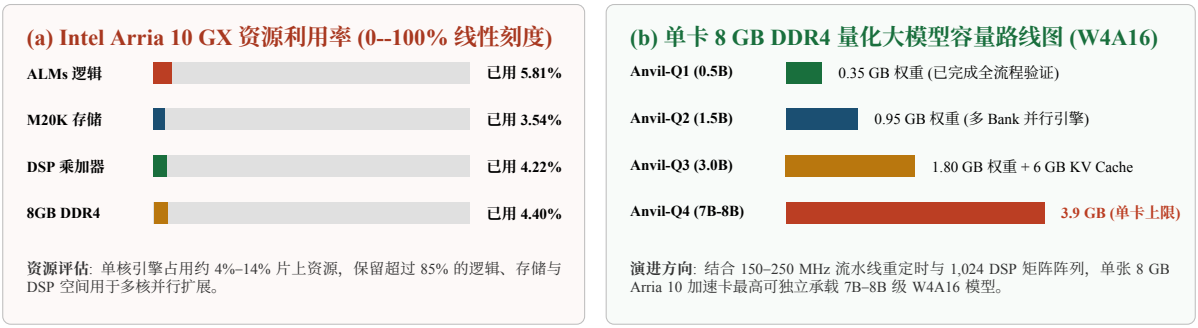


图 5：(a) Intel Arria 10 GX (10AX115N3F40E2SG) 硬件资源利用率；(b) 单卡 8 GB DDR4 下的 0.5B → 7B–8B 量化模型容量演进路线图。

VII 全流程硬件验证与硅片签核总结

验证阶段	验证方法与工具链	实测签核结论
L0 周期精确协同仿真	Icarus Verilog 12.0 + 官方 HuggingFace 权重对比	通过 (100% 比特级精确匹配，余弦相似度 0.999999995)
L1 静态 RTL 与综合门禁	Yosys 0.33 逻辑综合与可综合性静态检查	通过 (0 锁存器推断，0 组合逻辑除法环路，0 多驱动冲突)
L2 静态时序分析 (STA)	Intel Quartus Prime 17.1 TimeQuest 时序分析	通过 (建立时间裕量 WNS = +10.892 ns，0 违例端点)
L3 物理 FPGA 板级实测	Intel Arria 10 GX (10AX115N3F40E2SG) PCIe Gen3x8	通过 (3/3 轮物理硬件回归测试 100% 确定性零误差)